

UNIVERSIDAD EXTERNADO DE COLOMBIA

Ciencia de datos

MACHINE LEARNING II

Proyecto Integrador

**Detección de Population Drift en modelos de
predicción de gravedad clínica de COVID-19 en
Colombia**

Primera Entrega

Comprensión del artículo y planteamiento del problema

Integrantes:

Ailyn Sofía Gómez Rodríguez
Juan Tomas Rincón Pinzón

Docente:

Wilmer Darío Pineda Ríos

Bogotá D.C., Colombia
2026

Introducción

Los modelos de aprendizaje automático aplicados a contextos reales pueden perder desempeño cuando la población sobre la que predicen cambia respecto a la observada durante el entrenamiento, fenómeno conocido como *population drift* ($P_{train}(X) \neq P_{deploy}(X)$). Este problema es particularmente relevante en el ámbito médico, donde los perfiles de los pacientes pueden modificarse por cambios epidemiológicos, demográficos, tecnológicos o clínicos, y donde verificar directamente si un modelo sigue funcionando bien requiere etiquetas de verdad (*ground truth*) costosas y lentas de obtener. Este proyecto toma como punto de partida el trabajo de Jones y Farrow (2025), quienes proponen un One-Class Support Vector Machine (OCSVM) para detectar *population drift* sin depender de dichas etiquetas, y adapta ese enfoque al contexto colombiano de la pandemia de COVID-19, combinando un problema predictivo de gravedad clínica con una capa de monitoreo de drift.

1. Comprensión y sustentación del artículo

1.1. Problema y método

Los modelos de ML en diagnóstico médico suelen entrenarse sobre una población específica de pacientes; al desplegarse, la población real puede diferir de la de entrenamiento por cambios demográficos, nuevos equipos o procedimientos de adquisición, o transformaciones en las prácticas clínicas. Jones y Farrow (2025) abordan este problema proponiendo un One-Class SVM (kernel RBF, gamma automático, $\nu = 0,01$) entrenado sobre el conjunto Wisconsin Breast Cancer (569 pacientes, 30 variables reducidas a 21 tras filtrar colinealidad, balanceado con SMOTE y escalado). A diferencia de un clasificador supervisado, el OCSVM no usa la variable objetivo: aprende la región del espacio de variables que representa la población esperada durante el entrenamiento, y clasifica nuevas observaciones como *inliers* (consistentes con esa población) u *outliers* (posible señal de *population drift*). El modelo funciona así como una capa de monitoreo de la población de entrada, no como un diagnóstico directo.

1.2. Supuestos principales

El enfoque asume que (1) la distribución de entrenamiento representa adecuadamente la población clínica prevista (*intended use*); (2) un cambio en el espacio de variables de entrada es un proxy razonable de un cambio poblacional clínicamente relevante; y (3) $\nu = 0,01$ refleja una tasa esperada de contaminación cercana al 1 % en el conjunto de referencia.

1.3. Resultados y limitaciones

Los autores evaluaron el modelo generando poblaciones con desplazamientos de $\pm 0,4$ desviaciones estándar en `radius_mean` y ruido gaussiano de 5 %, 10 % y 30 % (10.000 registros por nivel). A mayor ruido, mayor solapamiento con la población de entrenamiento y, por tanto, mayor proporción de registros clasificados como *inliers* (Cuadro 1), lo que confirma que el OCSVM detecta cambios claros pero pierde sensibilidad ante desplazamientos sutiles.

Cuadro 1: Registros clasificados como *inliers* según el nivel de ruido.

Nivel de ruido	Registros clasificados como <i>inliers</i>
5 %	0,27 %
10 %	4,86 %
30 %	8,51 %

Entre las limitaciones reconocidas por los autores destacan: baja explicabilidad (no se identifica qué variable específica genera la clasificación de outlier); salida binaria que descarta información continua; validación únicamente sobre datos simulados, no poblaciones reales; ausencia de comparación con otros métodos de detección de anomalías (p. ej. Isolation Forest) o de reducción de dimensionalidad; y una simulación relativamente simple que no reproduce covarianzas reales entre variables. En conjunto, el OCSVM se entiende como una herramienta de monitoreo, no como prueba definitiva de un cambio clínicamente relevante.

2. Planteamiento del problema

2.1. Problema predictivo y variable objetivo

El proyecto adapta el enfoque de detección de population drift al contexto colombiano de COVID-19. El problema predictivo consiste en clasificar la gravedad clínica de un caso de COVID-19 a partir de variables demográficas y clínicas disponibles al momento del diagnóstico. La variable objetivo es binaria y se construye a partir del campo Estado del INS, agrupando los casos en grave/fallecido y leve/moderado/recuperado. Los predictores considerados incluyen edad, sexo, departamento o ciudad, tipo de atención y tipo de contagio, entre otras variables disponibles.

2.2. Relevancia y adaptación del método

La pandemia constituye un escenario adecuado para estudiar population drift porque la población de pacientes cambió a lo largo del tiempo con la aparición de nuevas variantes (Delta, Ómicron) y el avance de la vacunación. Esto permite un caso de interés real: un modelo entrenado con pacientes de la primera ola puede recibir posteriormente pacientes de olas con perfiles demográficos y clínicos distintos. El método que se reproduce del artículo es el OCSVM como capa de monitoreo: se construirá primero un modelo predictivo de gravedad con las técnicas del curso y, de manera independiente, un OCSVM entrenado solo con las variables de entrada del período de entrenamiento (sin la variable objetivo), que permitirá evaluar si los pacientes de períodos posteriores son consistentes con la población original o constituyen posibles outliers.

3. Estrategia de datos

3.1. Fuente y caracterización

La estrategia combina datos reales y simulación fundamentada. El conjunto principal es *Casos positivos de COVID-19 en Colombia* (Instituto Nacional de Salud, datos.gov.co), con varios millones de registros —muy por encima del mínimo de 5.000—, e incluye fecha de notificación, edad, sexo, departamento, ciudad, tipo de contagio, ubicación de atención y estado del caso. La variable objetivo será la gravedad clínica (binaria); los predictores, las variables demográficas y clínicas antes mencionadas. El conjunto final superará los 5.000 registros y será sometido a limpieza (nulos, categorías, consistencia temporal) en la siguiente fase.

3.2. División temporal

Para representar un escenario realista de drift, la partición no será aleatoria sino temporal: la población de entrenamiento corresponderá a la primera ola de la pandemia (2020, variante original, sin vacunación), mientras que las poblaciones de períodos posteriores (Delta 2021, Ómicron 2022, con vacunación en curso) representarán posibles escenarios de despliegue. Esta estrategia reproduce la lógica del artículo —entrenar sobre una población y evaluar sobre otra potencialmente distinta— con un desplazamiento que no es arbitrario, sino documentado en el contexto real de la pandemia.

3.3. Simulación fundamentada

Además de la partición temporal, se realizará una simulación controlada que reproduce directamente el diseño experimental de Jones y Farrow: a partir de la población de entrenamiento se generarán poblaciones sintéticas desplazando la variable edad en aproximadamente $\pm 0,4$ desviaciones estándar, con ruido gaussiano de 5 %, 10 % y 30 % de la desviación estándar. La edad se elige por su relevancia reconocida en la gravedad de COVID-19. Esta simulación cumple una función de control experimental: mientras la partición temporal permite estudiar un posible drift presente en los datos reales, las poblaciones simuladas permiten controlar explícitamente la magnitud del desplazamiento y comparar el comportamiento del OCSVM bajo distintos niveles de ruido, de forma comparable con el Cuadro 1 del artículo.

4. Plan de modelamiento y línea base

4.1. Modelos candidatos y monitoreo de drift

Para el problema de gravedad se compararán modelos de ensamble (Random Forest, Boosting—XGBoost o LightGBM—) y una SVM con kernel RBF, en línea directa con la metodología del artículo base. De manera independiente, se implementará un OCSVM (kernel RBF, gamma automático, $\nu = 0,01$ como punto de partida, calibrable según los datos colombianos) entrenado solo con las variables de entrada de la población de entrenamiento, evaluado sobre la propia población de entrenamiento, las poblaciones de períodos posteriores y las poblaciones sintéticas con ruido controlado.

4.2. Métricas y validación

Dado el desbalance esperado entre casos graves/fallecidos y leves/moderados/recuperados, la métrica principal para el modelo predictivo será el F1-score y el AUC-PR de la clase minoritaria, priorizando la detección de casos graves frente al costo de un falso negativo. Para el OCSVM se analizará la proporción de inliers/outliers en cada población evaluada. Dentro de la población de entrenamiento se usará validación cruzada estratificada ($k = 5$) para el ajuste de hiperparámetros, y el desempeño se evaluará fuera de muestra sobre las poblaciones temporales posteriores, evitando fuga de información al ajustar cualquier transformación únicamente con los datos de entrenamiento de cada partición.

4.3. Línea base

Como referencia mínima se usarán un clasificador de mayoría y una regresión logística simple (nivel Machine Learning I), frente a los cuales se medirá si la complejidad de los modelos avanzados realmente aporta una mejora.

Conclusión

El proyecto traslada el problema de population drift de Jones y Farrow (2025) a la predicción de gravedad clínica por COVID-19 en Colombia, combinando un modelo predictivo supervisado con un OCSVM que monitorea si los pacientes recibidos siguen siendo comparables a la población de entrenamiento. El uso de datos reales del INS junto con una simulación fundamentada permite estudiar el fenómeno desde una perspectiva real y otra controlada. Esta primera entrega sienta las bases para consolidar los datos, construir el flujo reproducible y ejecutar la adaptación experimental del método en la siguiente fase.

Nota sobre el uso de IA

El equipo utilizó herramientas de inteligencia artificial generativa como apoyo para estructurar y redactar este documento, a partir de las decisiones metodológicas discutidas y tomadas por el equipo. Todas las decisiones técnicas presentadas pueden ser explicadas y sustentadas por los integrantes.

Referencias

- [1] Jones, W. S., & Farrow, D. J. (2025). One-class support vector machines for detecting population drift in deployed machine learning medical diagnostics. *Scientific Reports*, 15, 12157.