

Universidad Externado de Colombia

Facultad: Ciencia de Datos
Asignatura: Machine Learning II — Proyecto Integrador
Docente: Wilmer Darío Pineda Ríos

Detección de Population Drift en modelos de predicción de gravedad clínica de COVID-19 en Colombia

Segunda Entrega — Fase 2: Datos, Modelamiento y Validación

Integrantes: - Ailyn Sofía Gómez Rodríguez - Juan Tomás Rincón Pinzón
Bogotá D.C., Colombia — 2026

Introducción

Esta segunda entrega consolida el flujo de modelamiento avanzado propio de Machine Learning II: integra el conjunto de datos depurado, construye un flujo reproducible sin fuga de información, reproduce y adapta el método de Jones y Farrow (2025) y evalúa los modelos con rigor estadístico. El proyecto articula dos componentes complementarios: (1) un **modelo supervisado de predicción de gravedad clínica**, y (2) un **One-Class Support Vector Machine (OCSVM)** no supervisado que monitorea el *population drift* en el espacio de covariables de entrada $P(X)$. El trabajo aporta un hallazgo metodológico central y honesto: en los datos colombianos del Instituto Nacional de Salud (INS), la aparente variación en el desempeño del modelo entre 2020 y 2022 no obedece a un *covariate drift* (las distribuciones de X permanecen estables según tests de Kolmogorov-Smirnov y el monitor OCSVM), sino a un **cambio drástico en la prevalencia clínica** (la tasa base de gravedad cayó de 2,82 % a 1,10 % por el efecto combinado de la vacunación masiva y las variantes virales). Dado que el OCSVM únicamente observa las variables de entrada X sin etiquetas, no detecta —ni debe detectar— cambios exclusivos en la distribución del objetivo ($P(Y)$ o $P(Y|X)$), delimitando con precisión su alcance práctico.

1. Consolidación de los Datos

1.1. Fuente, Calidad y Depuración

Se utilizó el registro oficial de **"Casos positivos de COVID-19 en Colombia"** del Instituto Nacional de Salud (portal datos.gov.co, recurso gt2j-8ykr, licencia CC BY-SA 4.0). El conjunto crudo contiene **6 390 844 registros** y 9 variables. El Cuadro 1 detalla las etapas de depuración aplicadas.

Cuadro 1. Estado de calidad del dataset del INS y etapas de depuración.

Etapas / Filtro	Registros	Proporción	Justificación Metodológica
Registros crudos	6 390 844	100,0 %	Descarga completa oficial del INS (9 variables).
Exclusión de estado nulo	-41 267	-0,65 %	Casos sin desenlace clínico registrado ni gravedad.
Filtro temporal (2020–2022)	-38 172	-0,60 %	Exclusión de fase endémica 2023–2024 fuera del alcance.
Control de rango edad [0, 115]	-0	0,0 %	Verificación de plausibilidad biológica.
Total depurado consolidado	6 311 405	98,75 %	Prevalencia global de gravedad = 2,26 %.

No se identificaron valores nulos en edad, sexo ni fechas de notificación. Las 1 057 entidades municipales se agruparon en las 15 principales capitales y una categoría consolidada *"Otros municipios"*.

1.2. Definición del Problema Predictivo y Predictores

- Variable Objetivo (grave):** Clasificación binaria donde $grave = 1$ si $estado \in \{Fallecido, Grave\}$ o $ubicación = "Hospital UCI"$; y $grave = 0$ si $estado \in \{Leve, Moderado\}$.
- Predictores seleccionados (4):** `edad_anios` (numérica continua), `sexo` (binaria), `ciudad_top` (categórica de 16 niveles) y `fuentes_tipo_contagio` (categórica).
- Ajustes justificados frente a la Entrega 1:** Se descartó *"tipo de atención"* por contener información directa del desenlace (*Fallecido*, *UCI*), lo que habría provocado fuga de datos hacia el objetivo.

1.3. Partición Temporal y Muestreo Estratificado

Siguiendo la lógica del artículo base, la partición es **temporal**: la cohorte de 2020 (variante ancestral, población virgen a vacunación) conforma el conjunto de entrenamiento, mientras que 2021 (Delta) y 2022 (Ómicron, vacunación activa) constituyen los escenarios de evaluación de despliegue. Para garantizar viabilidad computacional y balance temporal estricto, se extrajo una muestra estratificada de **100 000 casos por ola** (300 000 registros en total, superando ampliamente el mínimo de 5 000 de la guía). La Figura 1 verifica la estructura: la edad se concentra en adultos jóvenes en leves y se desplaza hacia adultos mayores en casos graves.




Figura 1. Verificación de la estructura del dataset consolidado: distribución de edad por clase, prevalencia por ola y distribución geográfica.

1.4. Simulación Fundamentada

Se adaptó el diseño experimental de Jones y Farrow: a partir de la cohorte de entrenamiento (2020), se modeló un **drift de envejecimiento poblacional** anclado en el percentil 99 de la edad ($85 \text{ años} + 0,4\sigma \approx 92,2 \text{ años}$, con $\sigma = 17,98$), incorporando ruido gaussiano de 5 %, 10 % y 30 % de σ . La simulación es clínicamente coherente: la letalidad por COVID-19 en Colombia se incrementa de forma monótona con la edad (0,1 % en menores de 18 años a más de 30 % en mayores de 80 años), convirtiendo un desplazamiento hacia edades avanzadas en el escenario de mayor riesgo predictivo. El Cuadro 2 y la Figura 2 confirman que la simulación reproduce la estructura teórica prevista.

Cuadro 2. Verificación estadística de las poblaciones simuladas frente a la población real.

Población	Media (años)	Desv. Estándar (σ)	P5	Mediana (P50)	P95
2020 Train (Real)	39,87	17,98	14,0	37,0	73,0
Simulación 5 % ruido	92,19	0,90	90,7	92,2	93,7
Simulación 10 % ruido	92,19	1,80	89,2	92,2	95,1
Simulación 30 % ruido	92,18	5,41	83,3	92,2	101,1




Figura 2. Distribución de edad real (2020) frente a las cohortes simuladas de envejecimiento bajo tres niveles de dispersión.

2. Flujo Reproducible sin Fuga de Datos

El preprocesamiento y el modelado se articularon en una arquitectura Pipeline de scikit-learn acoplada con ColumnTransformer, fijando la semilla aleatoria global SEED = 42. El orden de transformación garantiza la ausencia de fuga de datos (data leakage):

- Partición temporal ex-ante:** La separación entre 2020 (entrenamiento) y 2021–2022 (despliegue) se efectúa antes de cualquier cálculo estadístico.
- Transformaciones en el Pipeline:** La estandarización de edad_anios (StandardScaler) y la codificación de variables categóricas (OneHotEncoder(drop='first', handle_unknown='ignore')) se ajustan **exclusivamente con los datos de entrenamiento** de cada fold de validación cruzada.
- Manejo de desbalance controlado:** Se implementó class_weight='balanced' y scale_pos_weight dentro de los estimadores, evitando la distorsión de variables discretas originada por interpolaciones fraccionarias de sobremuestreo sintético.
- Monitoreo ciego no supervisado:** El OCSVM se entrena de forma estrictamente ciega a la variable objetivo grave.

3. Reproducción y Adaptación del Método

3.1. Réplica Experimental sobre Wisconsin Breast Cancer

Previo a la adaptación local, se reproduce el experimento de Jones y Farrow (2025) sobre su dataset original (Wisconsin Breast Cancer): 30 variables reducidas a 21 tras eliminar colinealidades ($|r| > 0,90$), SMOTE a 714 registros, estandarización y OCSVM (kernel RBF, $\gamma = \text{auto}$, $\nu = 0,01$). Se evaluó el desplazamiento de mean radius en $\pm 0,4\sigma$ con ruido del 5 %, 10 % y 30 % promediando 5 semillas independientes (Cuadro 3). La réplica reproduce fielmente la **tendencia del artículo**: a mayor ruido se produce mayor solapamiento con la frontera de decisión aprendida y, consecuentemente, una menor tasa de detección de outliers.

Cuadro 3. Réplica experimental en Wisconsin Breast Cancer (5 semillas) frente al artículo base.

Nivel de Ruido	Inliers Paper (Jones & Farrow)	Inliers Nuestra Réplica (media $\pm$ desv)	Outliers Réplica
5 %	0,27 %	92,08 % $\pm$ 0,39 %	7,92 %
10 %	4,86 %	91,31 % $\pm$ 0,48 %	8,69 %
30 %	8,51 %	84,39 % $\pm$ 0,44 %	15,61 %

3.2. OCSVM en Colombia y Sensibilidad de ν

Se ajustó el OCSVM sobre una submuestra no supervisada de 5 000 registros de 2020. Para evaluar con rigor la **tasa de falsa alarma fuera de muestra (out-of-sample)**, se evaluaron los 95 000 registros restantes de 2020 no utilizados en el entrenamiento, obteniendo un **98,96 % de inliers** (falsa alarma real de 1,04 %, correspondiente exactamente a $\nu = 0,01$). Sobre las olas reales de despliegue, el OCSVM clasificó como inliers al **99,08 % en 2021** y al **97,99 % en 2022**, confirmando la estabilidad del soporte de X.

En las simulaciones de drift, el OCSVM detecta el corrimiento de edad reduciendo los inliers a 72,00 % con 30 % de ruido, mientras que **Isolation Forest** resulta insensible (100 % inliers) debido a que los cortes ortogonales en árboles no delimitan contornos de densidad compactos (Cuadro 4 y Figura 3). Asimismo, al calibrar ν ($\nu = 0,05 \rightarrow 9,30$ % inliers en Sim 30 %; $\nu = 0,10 \rightarrow 0,68$ % inliers), se comprueba que ν actúa como dial de compromiso entre sensibilidad y tasa de falsa alarma.

Cuadro 4. Proporción de inliers detectados por OCSVM e Isolation Forest en Colombia.

Cohorte Evaluada	Registros	OCSVM ($\nu = 0,01$) % Inliers	Isolation Forest % Inliers
2020 Train (In-sample)	5 000	99,00 %	99,00 %
2020 Test (Out-of-sample)	95 000	98,96 %	98,93 %
2021 Delta (Despliegue)	100 000	99,08 %	98,08 %
2022 Ómicron (Despliegue)	100 000	97,99 %	98,92 %
Simulación 5 % ruido	10 000	99,97 %	100,00 %
Simulación 10 % ruido	10 000	95,94 %	100,00 %
Simulación 30 % ruido	10 000	72,00 %	100,00 %




Figura 3. Sensibilidad al drift poblacional: comparación de la proporción de inliers entre OCSVM e Isolation Forest bajo distintos niveles de ruido.

3.3. Modelos de Gravedad Clínica y Línea Base

Se entrenaron y compararon: **Línea Base de Mayoría**, **Regresión Logística**, **Random Forest**, **XGBoost**, **LightGBM** y **SVM con kernel RBF exacto** (ajustado sobre submuestra representativa estratificada de 15 000 registros para garantizar convergencia matemática). Los hiperparámetros se optimizaron mediante `GridSearchCV` estratificado ($k = 5$) maximizando el Área Bajo la Curva Precisión-Sensibilidad (`average_precision`).

4. Validación, Métricas e Interpretación

4.1. Validación Cruzada y Variabilidad

Dado el desbalance severo (prevalencia ~2,8 %) y el alto costo clínico de los falsos negativos, la métrica principal es el **AUC-PR** (Precisión Promedio), complementada con ROC-AUC y F1-score. El Cuadro 5 reporta el desempeño con su **variabilidad estadística (media ± desv. estándar)** entre los 5 folds.

Cuadro 5. Desempeño en Validación Cruzada Estratificada ($k = 5$) en la cohorte 2020.

Modelo	Hiperparámetros Óptimos	AUC-PR (media ± desv)	ROC-AUC (media ± desv)	F1 ($t = 0,50$)	F1 ($t^* \approx 0,16$)
Reg. Logística	C: 0.1	0,268 ± 0,015	0,909 ± 0,003	0,090 ± 0,020	0,351 ± 0,016
LightGBM	lr: 0.05, n_est: 150, leaves: 15	0,266 ± 0,016	0,907 ± 0,002	0,027 ± 0,012	0,347 ± 0,020
XGBoost	lr: 0.1, depth: 3, n_est: 150	0,265 ± 0,020	0,908 ± 0,003	0,055 ± 0,019	0,350 ± 0,018
Random Forest	depth: 10, n_est: 200	0,252 ± 0,014	0,904 ± 0,004	0,023 ± 0,007	0,337 ± 0,020
SVM-RBF (Exacto)	C: 0.5, gamma: auto	0,252 ± 0,029	0,909 ± 0,008	0,000 ± 0,000	0,252 ± 0,029
Línea Base (Mayoría)	strategy: most_frequent	0,028 ± 0,000	0,500 ± 0,000	0,000 ± 0,000	0,000 ± 0,000

Hallazgo Metodológico: Con 4 predictores demográficos y clínicos, los modelos de ensamble avanzado y SVM **no superan estadísticamente a la Regresión Logística**; las diferencias en AUC-PR (0,268 vs 0,265) son inferiores a la desviación estándar entre folds ($\pm 0,015$). En virtud del principio de parsimonia e interpretabilidad clínica, la **Regresión Logística es seleccionada como el mejor modelo**. Asimismo, la optimización del umbral de decisión a $t^* \approx 0,16$ eleva el F1-score de 0,09 a 0,351, logrando una sensibilidad clínica de 45,2 % y precisión de 28,8 %.

4.2. Validación Cruzada Anidada (Nested CV)

Para obtener una estimación no sesgada del error de generalización y controlar el sesgo de selección de hiperparámetros (Criterio 7.4 de la guía), se ejecutó una **Validación Cruzada Anidada (5 folds externos × 3 folds internos)** (Cuadro 6). Los resultados confirman la consistencia de la Regresión Logística y demuestran que el desempeño se mantiene robusto sin sobreajuste.

Cuadro 6. Estimación no sesgada mediante Validación Cruzada Anidada (5 outer × 3 inner).

Modelo	Nested AUC-PR (media ± desv)	Nested ROC-AUC (media ± desv)	Nested F1 (media ± desv)
Reg. Logística	0,2662 ± 0,0143	0,9089 ± 0,0027	0,2161 ± 0,0048
XGBoost	0,2658 ± 0,0192	0,9078 ± 0,0029	0,2118 ± 0,0052
LightGBM	0,2657 ± 0,0198	0,9075 ± 0,0022	0,2176 ± 0,0053

4.3. Evaluación Temporal Fuera de Muestra: ¿Covariate Drift o Prevalence Drift?

Al evaluar la Regresión Logística en 2021 y 2022 (Cuadro 7), el **ROC-AUC se mantiene excelente e incluso aumenta (0,892 en 2021 → 0,921 en 2022)**. El AUC-PR absoluto desciende de 0,199 a 0,185 debido exclusivamente a la caída de la tasa base (2,33 % → 1,10 %); no obstante, el **desempeño relativo a la prevalencia se duplica (8,6× → 16,9×)**.

Los tests de Kolmogorov-Smirnov sobre la edad frente a 2020 (D = 0,026 en 2021 y D = 0,061 en 2022) confirman que la distribución de las variables de entrada es estable. Por ende, **el fenómeno observado es un cambio de prevalencia (prior drift), no un covariate drift**. Las Figuras 4 y 5 ilustran las curvas PR y ROC del modelo seleccionado sobre 2021.

Cuadro 7. Evaluación temporal fuera de muestra del modelo seleccionado (Regresión Logística).

Periodo / Ola	Prevalencia Real	ROC-AUC	AUC-PR	Ratio AUC-PR / Prevalencia	Brier Score
2021 (Delta)	2,33 %	0,892	0,199	8,6× sobre tasa base	0,109
2022 (Ómicron)	1,10 %	0,921	0,185	16,9× sobre tasa base	0,163




Figura 4. Curva Precisión-Sensibilidad del mejor modelo (Regresión Logística) sobre la cohorte 2021 (Delta).




Figura 5. Curva ROC del mejor modelo (Regresión Logística) sobre la cohorte 2021 (Delta).

4.4. Interpretación Preliminar de Variables

El análisis de **importancia por permutación** sobre la cohorte 2021 (Figura 6) demuestra que la **edad es el factor clínico preponderante**, generando una disminución de $0,1730 \pm 0,0004$ en AUC-PR al ser permutada. Le siguen en menor magnitud el sexo ($0,0189 \pm 0,0015$), la fuente de contagio ($0,0182 \pm 0,0025$) y la ciudad ($0,0070 \pm 0,0020$). Esto convalida plenamente la decisión de centrar la simulación de drift en la variable etaria.




Figura 6. Importancia de variables por permutación (disminución en AUC-PR) para la Regresión Logística.

Conclusión

La Segunda Entrega consolidó un flujo de modelamiento reproducible y sin fuga sobre 300 000 casos del INS. Se replicó con rigor el método de Jones y Farrow (2025) en Wisconsin y se adaptó al contexto colombiano mediante simulación de envejecimiento. El hallazgo metodológico es contundente: el cambio en el comportamiento del modelo de gravedad entre 2020 y 2022 se debe a un **cambio de prevalencia epidemiológica y no a un drift de covariables**, un límite intrínseco del OCSVM que monitorea únicamente P(X). La comparación en validación

anidada demuestra un empate estadístico entre clasificadores, justificando la selección de la Regresión Logística. Para la Entrega Final se profundizará en explicabilidad individual (SHAP), recalibración Bayesiana de probabilidades y despliegue funcional en Streamlit.

Nota sobre el uso de IA

El equipo utilizó herramientas de inteligencia artificial generativa como apoyo para estructurar el código reproducible y la redacción técnica del informe, a partir de las decisiones analíticas tomadas por los integrantes. Todas las decisiones metodológicas pueden ser sustentadas por el equipo.

Referencias

- [1] Jones, W. S., & Farrow, D. J. (2025). One-class support vector machines for detecting population drift in deployed machine learning medical diagnostics. *Scientific Reports*, 15, 12157.
- [2] Instituto Nacional de Salud (INS). *Casos positivos de COVID-19 en Colombia*. Datos Abiertos Colombia. <https://www.datos.gov.co/Salud-y-Proteccion-Social/Casos-positivos-de-COVID-19-en-Colombia/gt2j-8ykr>
- [3] Schölkopf, B., et al. (2001). Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7), 1443–1471.
- [4] Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [6] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of KDD*, 785–794.
- [7] Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- [8] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proceedings of ICDM*, 413–422.