

Universidad Externado de Colombia

Facultad: Ciencia de datos **Asignatura:** Machine Learning II **Proyecto Integrador**

Detección de Population Drift en modelos de predicción de gravedad clínica de COVID-19 en Colombia

Segunda Entrega — Fase 2: datos, modelamiento y validación

Integrantes:

- Ailyn Sofía Gómez Rodríguez
- Juan Tomas Rincón Pinzón

Docente: Wilmer Darío Pineda Ríos

Bogotá D.C., Colombia

2026

Introducción

Esta segunda entrega ejecuta la Fase 2: consolida el conjunto de datos, construye un flujo de modelamiento reproducible sin fuga, reproduce y adapta el método del artículo base (Jones y Farrow, 2025) y evalúa los modelos con rigor. El proyecto mantiene dos piezas independientes y complementarias: (1) un **modelo supervisado de gravedad clínica** (el "diagnóstico ML desplegado"), y (2) un **OCSVM** que monitorea el population drift —el cambio en la distribución de las variables de entrada entre entrenamiento y despliegue—, que es el método que se reproduce del artículo. Esta entrega aporta un hallazgo honesto y matizado: en los datos colombianos, el desempeño del modelo de gravedad no se degrada por un drift de covariables, sino por un **cambio de prevalencia** (la proporción de casos graves cayó con la vacunación y las variantes), un fenómeno que el OCSVM —que solo observa las variables de entrada— no puede, ni debe, detectar.

1. Consolidación de los datos

1.1. Fuente y calidad

El conjunto es "**Casos positivos de COVID-19 en Colombia**" del Instituto Nacional de Salud (datos.gov.co, recurso gt2j-8ykr, licencia CC BY-SA 4.0). Se descargaron **6 390 844 registros** con 9 columnas. El Cuadro 1 resume el proceso de calidad.

Cuadro 1. Estado de calidad de los datos y transformaciones.

Paso	Registros	Observación
Crudos	6 390 844	9 columnas
estado nulo	-41 267 (0,65 %)	sin gravedad registrada, se excluyen
Fecha fuera de 2020-2022	-~39 300	2023-2024 (fase endémica, fuera de alcance)
Edad fuera de [0, 120]	-0	filtro de resguardo, no eliminó filas
Tras filtros	6 349 577	prevalencia grave = 2,26 %

Notas de calidad: no hay nulos en edad, sexo ni fechas; 1 057 municipios (agrupados a 16); 3,1 M de filas idénticas en las 9 columnas (48,7 %), que **no son duplicados reales** —la columna ID de caso no se descargó y con 9 variables es esperable que pacientes distintos compartan valores—, por lo que no se eliminaron.

1.2. Variable objetivo y predictores

- **Objetivo grave:** grave = 1 si estado ∈ {Fallecido, Grave} o ubicación = "Hospital UCI"; grave = 0 si estado ∈ {Leve, Moderado}. Prevalencia global 2,26 %.
- **Predictores (4):** edad (años), sexo, ciudad (top-15 + "Otros municipios") y tipo de contagio.
- **Cambios respecto a la Entrega 1 (declarados):** se descartó "tipo de atención" porque contiene el desenlace (Fallecido, Hospital UCI) y filtraría el objetivo; la regla del objetivo ahora incluye explícitamente UCI y ya no usa "recuperado" (que en los datos es una columna de desenlace, no de gravedad); y se redujo a 4 predictores de bajo riesgo de fuga.

1.3. Partición temporal y muestreo

Partición **temporal** (no aleatoria), fiel a la lógica del artículo: 2020 (ola original, sin vacunación) como entrenamiento; 2021 (Delta) y 2022 (Ómicron) como despliegue. La prevalencia **desciende con el tiempo** (Cuadro 2), documentando el cambio de la tasa base. Tras ello, muestreo estratificado de **100 000 registros por ola** (300 000 en total). La Figura 1 verifica la estructura: la edad se concentra en adultos jóvenes, la clase grave es minoritaria y las ciudades capitales dominan el volumen (con "Otros municipios" como categoría agregada mayor).

Cuadro 2. Casos y prevalencia de gravedad por ola (antes del muestreo).

Ola	Casos	P(grave)
2020 (original)	1 746 914	2,82 %
2021 (Delta)	3 506 739	2,33 %
2022 (Ómicron)	1 057 752	1,10 %




Figura 1. Verificación de la estructura del dataset reducido.

1.4. Simulación fundamentada

Se reprodujo el diseño del artículo adaptándolo a la edad, la variable clave de gravedad. **Adaptación justificada:** el artículo desplaza una variable a sus extremos; en la edad, desplazar hacia el mínimo colapsaría en 0, por lo que se modeló un **drift de envejecimiento** —la población desplegada es más vieja— anclando en el percentil 99 de la edad (85 años) + $0,4 \sigma$ ($\sigma = 17,98$), con ruido gaussiano del 5 %, 10 % y 30 % de σ . Es realista: en los casos del INS la gravedad crece con la edad (P(grave) de 0,1 % en <18 años a 31,8 % en ≥ 80), de modo que un corrimiento hacia los adultos mayores es el drift de mayor riesgo clínico. La Figura 2 verifica que la simulación reproduce la estructura prevista (un cluster que se desplaza a ~92 años y cuya dispersión crece con el ruido: sd 0,90 / 1,81 / 5,43).




Figura 2. Distribución de edad real (2020) frente a las poblaciones simuladas de envejecimiento.

2. Flujo reproducible sin fuga de datos

Todo el preprocesamiento y el modelado se integró en `Pipeline` de `scikit-learn` (con `ColumnTransformer` y `Pipeline` de `imbalanced-learn`), con semilla fija (`SEED = 42`). Orden de etapas y prevención de fuga:

1. **Partición temporal antes de cualquier ajuste.**
2. **Preprocesamiento dentro del Pipeline** (imputación → one-hot → escalamiento), ajustado solo con el train de cada fold.
3. **SMOTE dentro del Pipeline**, generando sintéticos solo sobre el train de cada fold.
4. **ubicación excluida como predictor** (contiene el desenlace); solo se usó para construir `grave`.
5. **OCSVM entrenado sin la etiqueta** (no supervisado).

El código se entrega en `01_reduccion.ipynb` y `02_modelado.ipynb`, con `requirements.txt` y `src/descargar_ins.py` (descarga del dataset crudo).

3. Reproducción y adaptación del método

3.1. Validación de la reproducción en el propio terreno del artículo

Antes de adaptar, se **reprodujo el experimento del artículo sobre su propio dataset** (Wisconsin Breast Cancer): 21 variables tras eliminar las 9 colineales ($|r| > 0,9$), SMOTE hasta 714, estandarización, OCSVM (RBF, γ automático, $\nu = 0,01$) y desplazamiento de `radius_mean` $\pm 0,4 \sigma$ con ruido en todas las variables (5 semillas). El resultado coincide en orden de magnitud y tendencia con el artículo (Cuadro 3), lo que valida que nuestra implementación reproduce el método.

Cuadro 3. Réplica del experimento en Wisconsin (5 semillas) vs. artículo.

Ruido	Artículo	Nuestra réplica
5 %	0,27 %	0,08 %
10 %	4,86 %	2,28 %
30 %	8,51 %	3,75 %

3.2. OCSVM como capa de monitoreo y sensibilidad de ν

Se reprodujo el OCSVM (RBF, γ automático, $\nu = 0,01$) sobre 5 000 filas de 2020 (submuestreo por el costo $O(n^2)$ del kernel). Sobre las poblaciones simuladas reproduce la tendencia del artículo (Cuadro 4 y Figura 3): **a mayor ruido, más inliers** (23,4 % $\rightarrow$ 25,9 % $\rightarrow$ 36,7 %), porque el cluster desplazado se solapa más con la frontera.

Se evaluó la **sensibilidad de ν** (prometida como "calibrable" en la Entrega 1): con el drift al 30 %, $\nu = 0,01$ deja 36,7 % de inliers, $\nu = 0,05$ deja 1,5 % y $\nu = 0,10$ deja 0,1 %; el costo es la falsa alarma sobre 2020 no usada (99,1 % / 94,5 % / 89,4 % de inliers). Es decir, ν es el dial del compromiso sensibilidad/falsa alarma.

Cuadro 4. Proporción de inliers en poblaciones simuladas: artículo vs. nuestro OCSVM e Isolation Forest.

Ruido	Artículo	OCSVM (nuestro)	Isolation Forest
5 %	0,27 %	23,4 %	92,7 %
10 %	4,86 %	25,9 %	92,1 %
30 %	8,51 %	36,7 %	91,6 %

El **Isolation Forest** responde menos que el OCSVM (8 % de outliers vs. 63 % a 30 % de ruido). Verificamos que esto **no es un artefacto de la codificación one-hot**: entrenado solo con la edad numérica sigue siendo poco sensible (98,3 % de inliers). Es una diferencia genuina de sensibilidad entre métodos, a favor del OCSVM para este tipo de drift.




Figura 3. Proporción de inliers según el ruido para OCSVM e Isolation Forest.

3.3. Modelos de gravedad y línea base

Se compararon **Random Forest**, **XGBoost**, **LightGBM** y **SVM-RBF** (esta última con aproximación **Nystroem** para ser comparable sobre las 100 000 filas) frente a las líneas base de **mayoría** y **regresión logística**. Hiperparámetros con **GridSearchCV** (CV estratificada, $k = 5$, métrica AUC-PR) y **umbral elegido dentro de la CV** (maximizando F1), no fijo en 0,5.

4. Validación, métricas e interpretación

4.1. Métricas y umbral

Dado el desbalance y que el error costoso es el **falso negativo** (grave no detectado), se reportan **AUC-PR, F1, sensibilidad y precisión de la clase grave**, más ROC-AUC. El **umbral se seleccionó en validación cruzada**, lo que corrige la sobre-confianza inducida por SMOTE: el umbral óptimo resultó $\sim 0,86$ (no 0,5), elevando el F1 de $\sim 0,21$ a $\sim 0,35$.

Cuadro 5. Desempeño en validación cruzada (umbral elegido en CV).

Modelo	AUC-PR	ROC-AUC	F1 (umbral CV)
Reg. logística	0,265	0,909	0,346
SVM RBF (Nystroem)	0,267	0,908	0,346
XGBoost	0,264	0,907	0,344
LightGBM	0,256	0,906	0,339
Random Forest	0,228	0,901	0,318

La línea base de mayoría tiene $F1 = 0$ en CV y en las olas. **Hallazgo honesto:** con 4 predictores, los modelos avanzados **no superan a la regresión logística** (AUC-PR $\sim 0,26$ en todos, salvo Random Forest). El **mejor modelo elegido es la regresión logística**: empatado en discriminación, el más interpretable y estable, y el mejor fuera de muestra. La SVM-RBF se reporta como referencia del curso (con Nystroem ya es comparable), no como ganadora.

4.2. ¿Drift de covariables o cambio de prevalencia?

La evaluación temporal (Cuadro 6) muestra que el **ROC-AUC no cae** ($0,891 \rightarrow 0,921$ de 2021 a 2022) y que el **AUC-PR relativo a la prevalencia mejora** ($8,5\times \rightarrow 16,7\times$). La caída del AUC-PR absoluto se explica por el **descenso de la prevalencia** ($2,82\% \rightarrow 1,10\%$), no por pérdida de capacidad discriminativa.

Cuadro 6. Evaluación temporal (regresión logística).

Periodo	P(grave)	ROC-AUC	AUC-PR	AUC-PR / prevalencia
2021 (Delta)	2,33 %	0,891	0,198	8,5×
2022 (Ómicron)	1,10 %	0,921	0,183	16,7×

Esto es coherente con el monitor de drift: las **covariables apenas cambiaron** (KS de edad 0,026 en 2021 y 0,061 en 2022; PSI de las categóricas $\leq 0,13$), y el **OCSVM lo confirma** con $\sim 99\%$ de inliers en ambas olas, igual que su falsa alarma natural sobre 2020 no usada ($99,07\%$). En otras palabras: **lo que cambió en 2022 no fue la distribución de X, sino la tasa base**, un cambio de prior/calibración que el OCSVM — que solo observa X — no puede detectar. Este es un límite esperado del método, no un fallo, y refina la lectura de la Entrega 1.

La Figura 4 (curva PR) y la Figura 5 (ROC) del mejor modelo sobre 2021, junto con su matriz de confusión a umbral 0,86 (sensibilidad 0,37; precisión 0,23), y la **calibración** (en 2021, el tercer tercil predice 0,53 cuando la tasa real es 0,063), evidencian la sobreconfianza heredada de SMOTE y justifican el umbral ajustado en CV.




Figura 4. Curva precisión-sensibilidad del mejor modelo sobre 2021.




Figura 5. Curva ROC del mejor modelo sobre 2021.

4.3. Interpretación preliminar

La **importancia por permutación** (Figura 6) confirma que la **edad domina** el poder predictivo (0,189 de caída en AUC-PR al permutarla), seguida de sexo (0,027), tipo de contagio (0,023) y ciudad (0,012). Esto es clínicamente coherente y justifica la elección de la edad como variable de la simulación de drift. La estabilidad entre folds es razonable (desviaciones $\leq 0,02$ –0,06 en AUC-PR), y el error de mayor costo son los graves no detectados.




Figura 6. Importancia por permutación (disminución de AUC-PR) del mejor modelo.

Conclusión

La segunda entrega consolidó y verificó un dataset real colombiano (6,4 M registros del INS, reducidos a 300 000), reprodujo fielmente el OCSVM del artículo —validándolo primero en Wisconsin (0,08/2,28/3,75 % de inliers) y mostrando su sensibilidad a v —, y lo adaptó a un drift de envejecimiento justificado por la estructura etaria de los casos. El hallazgo central es matizado y honesto: en Colombia, el desempeño del modelo de gravedad **no se degrada por drift de covariables, sino por cambio de prevalencia**, un límite que el OCSVM no puede detectar por diseño. La comparación de modelos muestra que, con 4 predictores, la complejidad no aporta y la regresión logística es la elección razonable. Quedan para la entrega final la interpretación con SHAP y el despliegue.

Nota sobre el uso de IA

El equipo utilizó herramientas de inteligencia artificial generativa como apoyo para estructurar y redactar este documento y para construir y depurar el código reproducible, a partir de decisiones metodológicas discutidas y tomadas por el equipo. Todas las decisiones técnicas pueden ser explicadas y sustentadas por los integrantes.

Referencias

- [1] Jones, W. S., & Farrow, D. J. (2025). One-class support vector machines for detecting population drift in deployed machine learning medical diagnostics. *Scientific Reports*, 15, 12157.
- [2] Instituto Nacional de Salud (INS). Casos positivos de COVID-19 en Colombia. Datos Abiertos Colombia. <https://www.datos.gov.co/Salud-y-Proteccion-Social/Casos-positivos-de-COVID-19-en-Colombia/gt2j-8ykr>
- [3] Schölkopf, B., et al. (2001). Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7), 1443–1471.
- [4] Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [6] Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17), 1–5.
- [7] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of KDD*, 785–794.
- [8] Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- [9] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proceedings of ICDM*, 413–422.